

# Gray-Level Co-occurrence Matrixを用いた 画像認識による高速道路の渋滞予測

神戸大学大学院 工学研究科 市民工学専攻  
D2 安田 昌平 M1 小倉 大輝  
M1 佐々木 泰 M1 福嶋 一矢

# 概要

## ◆ 作品概要

東名高速や中央道などで発生する渋滞を首都圏の交通状態パターンから予測するため、これら時空間的な速度情報を可視化し画像データとして学習、類似候補同士を合成することで、交通状態の予測画像を生成した。

## ◆ 使用したインフラデータ

- ・高速道路情報（NEXCO東日本, NEXCO中日本）
- ・トラカンデータ（首都高速道路）
- ・商用車プローブデータ（富士通）
- ・デジタル道路地図データ（日本デジタル道路地図協会）

# 今回試みたこと

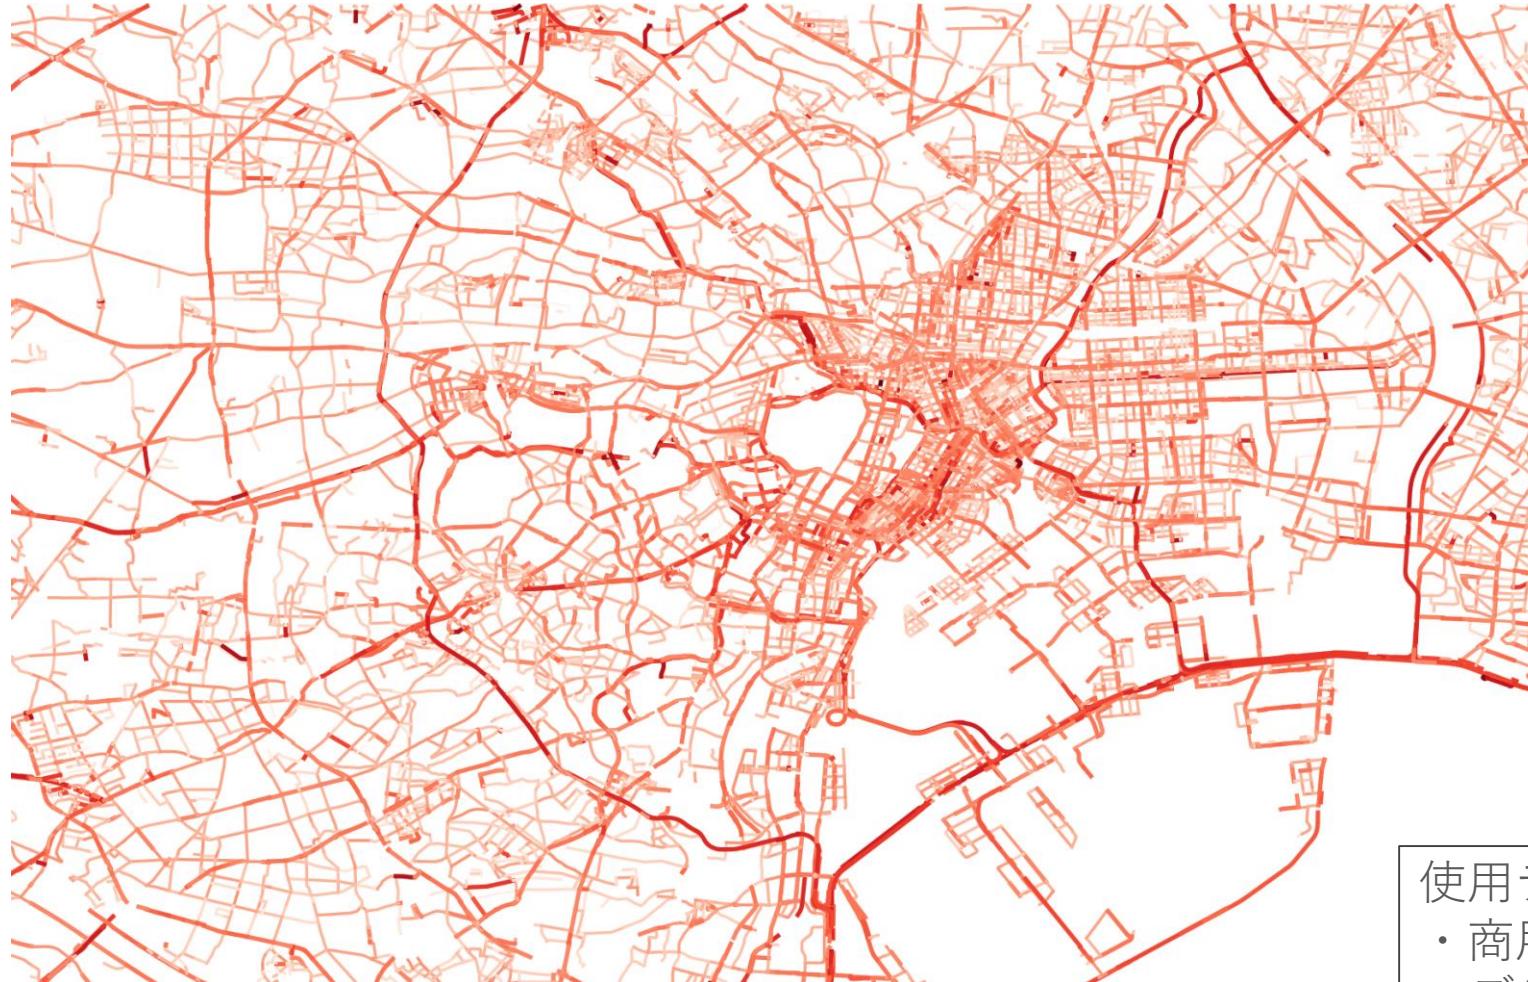
画像認識系の機械学習（パターン認識）手法を用いて、  
交通状態の時空間的な変動を学習させ、データに潜むパターンを  
見つけ出し、将来予測に生かす方法を構築・実装した。

今回構築した手法は、交通流のダイナミクスをモデル等を  
仮定せず、データから直接学習する手法である。

# 基礎分析（可視化）

# 自由流速度の推定

各DRMリンクについて、富士通プローブデータで観測された速度の90パーセンタイル値を自由流速度として推定



## 使用データ

- ・商用車プローブ
- ・デジタル道路地図

# 各時間帯の速度低下比率（推定自由流速度と比較）

2017/2/1 7:30~7:45

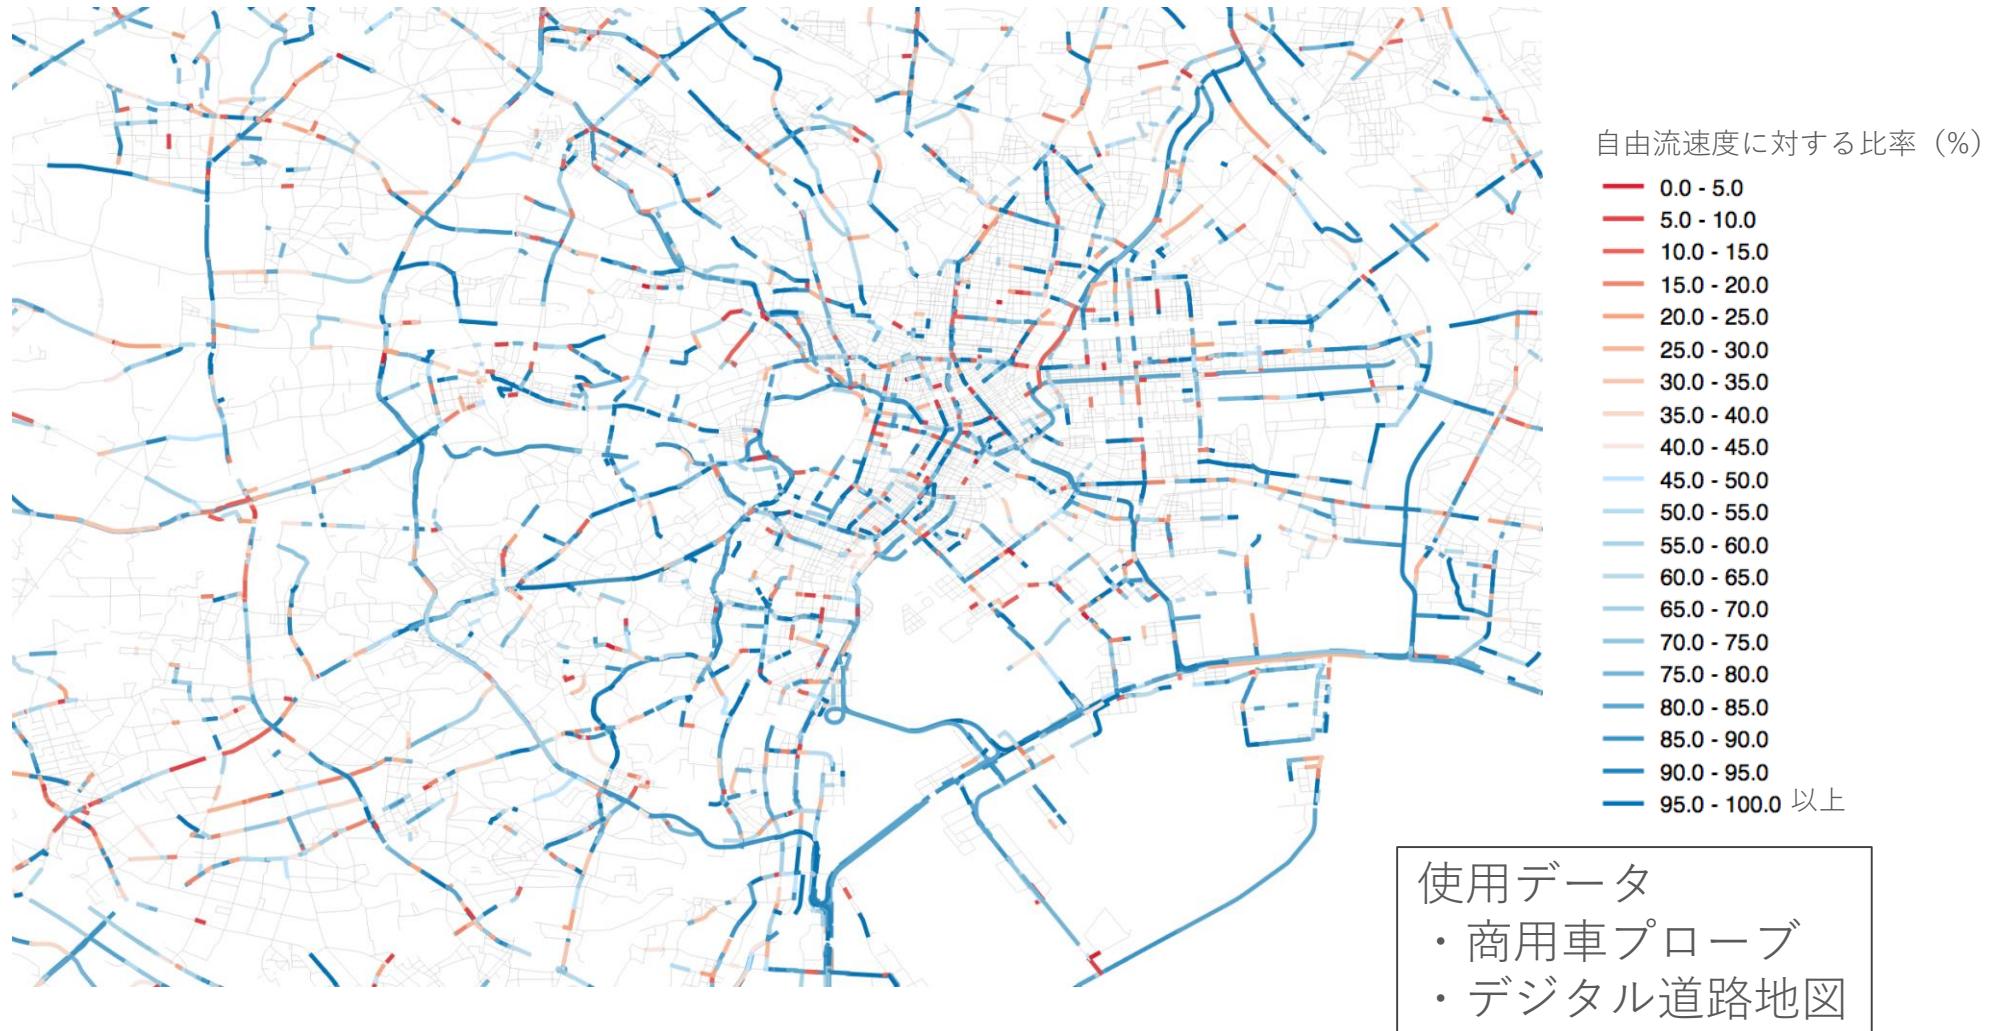


## 使用データ

- 商用車プローブ
- デジタル道路地図

# 各時間帯の速度低下比率（推定自由流速度と比較）

2017/2/1 7:45~8:00



# 各時間帯の速度低下比率（推定自由流速度と比較）

2017/2/1 8:00~8:15



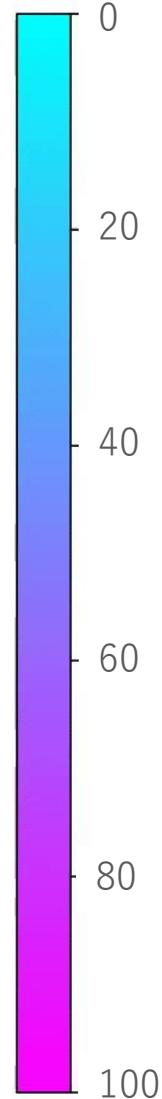
## 使用データ

- 商用車プローブ
- デジタル道路地図

# 速度低下比率（アニメーションで）

2017-02-01 00:00:00

速度低下率 (%)



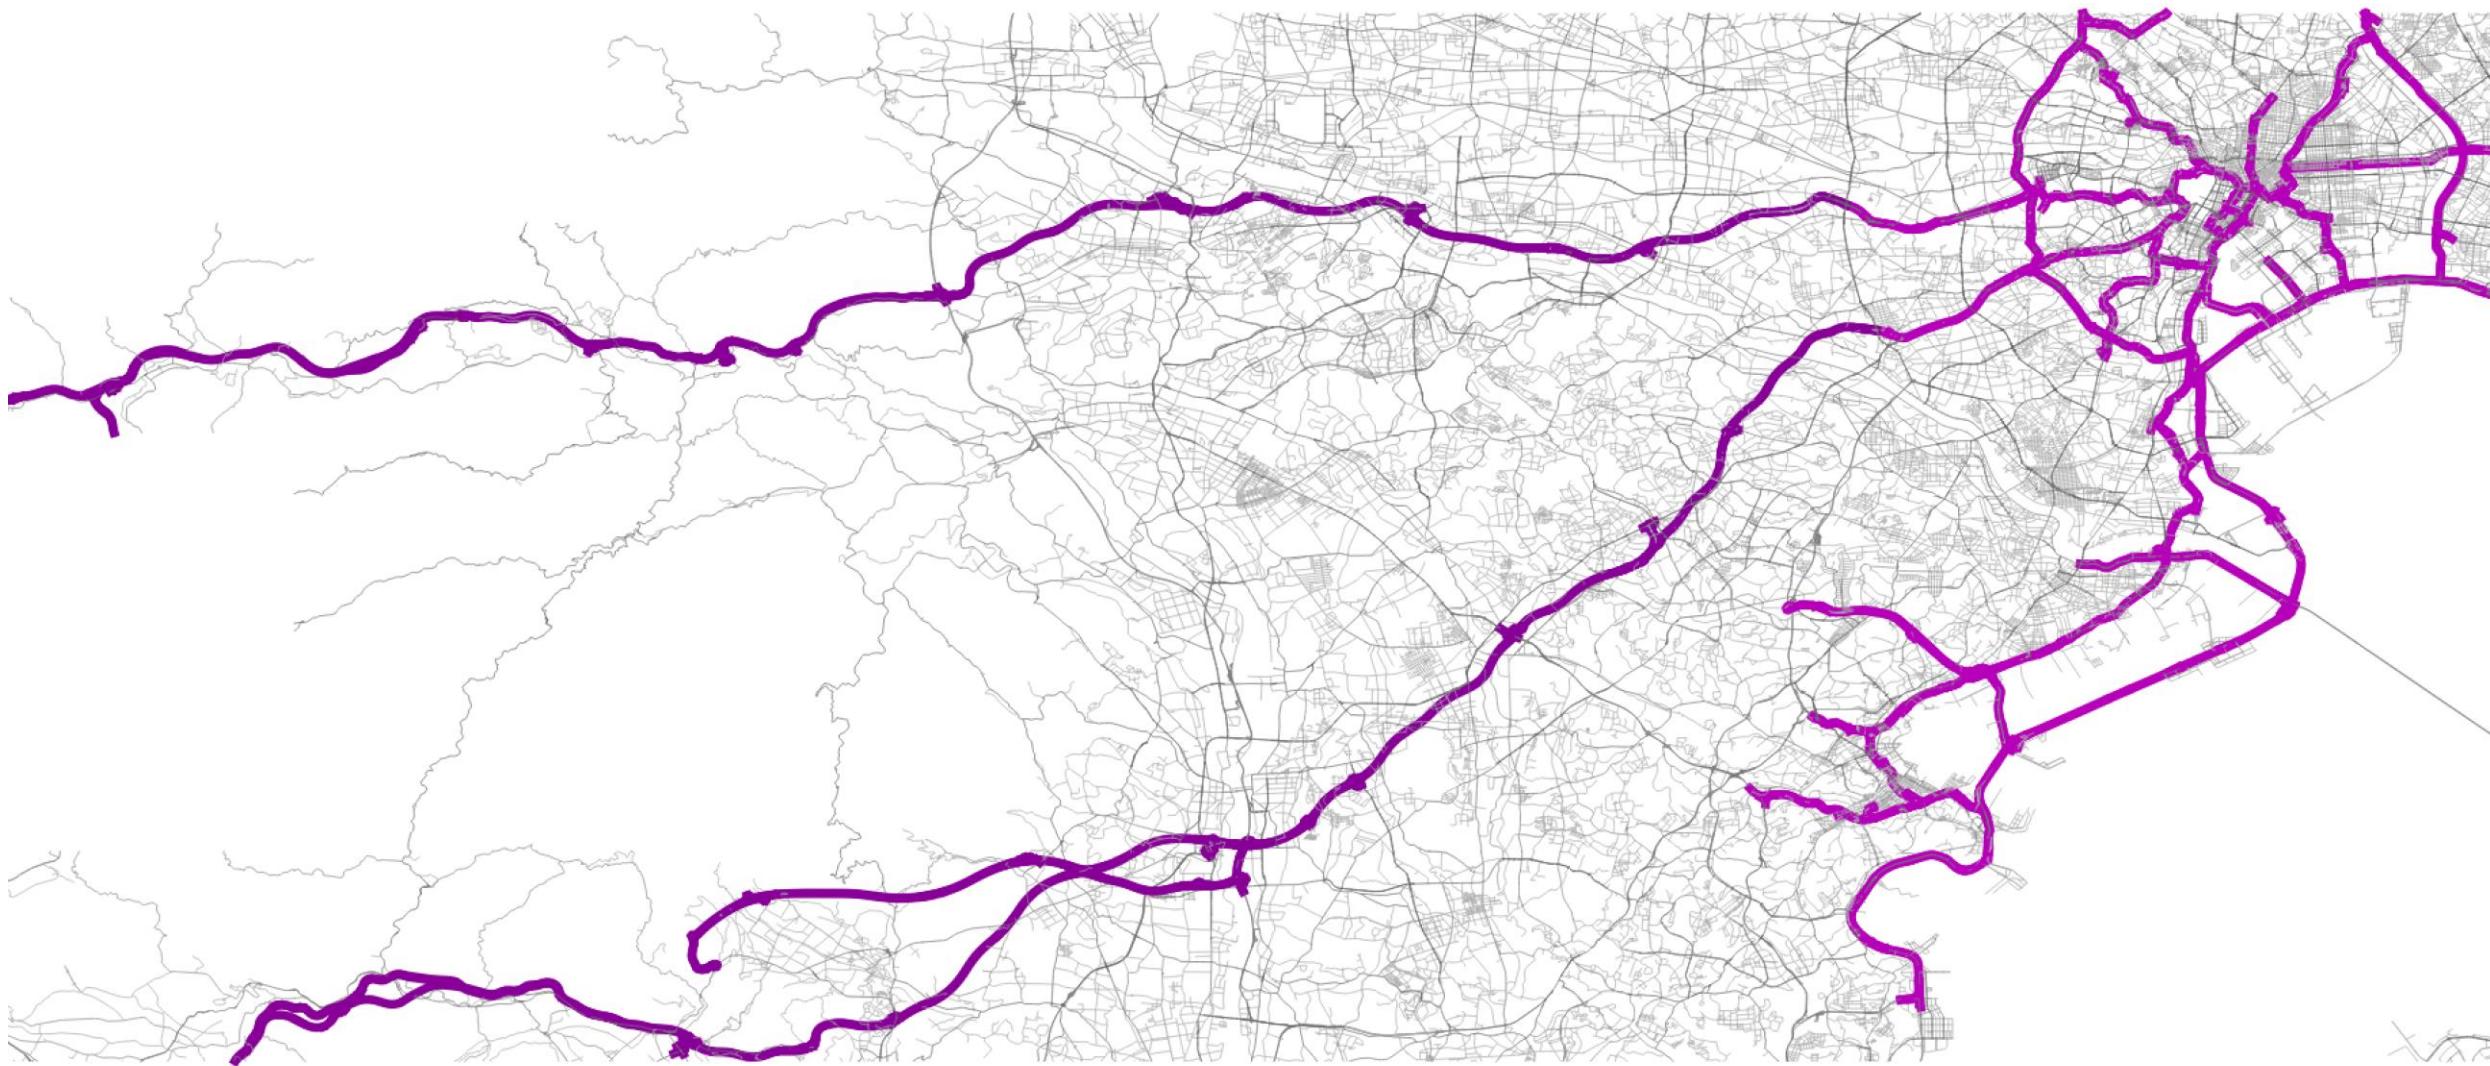
# 時空間的変動パターンの学習

単純な可視化により、**交通状態に関する時空間的な変動**を  
ひと目で直感的にイメージすることができる。  
→パターンを学習することで、予測に繋げられないか。

**画像（動画）認識系の機械学習アルゴリズム**を用いて、  
従来の交通流モデリングとは異なる観点から、**将来の交通状態**  
**予測**をdata-drivenに行ってみる。

# 分析対象

# 首都圏へ流入する主要高速道路



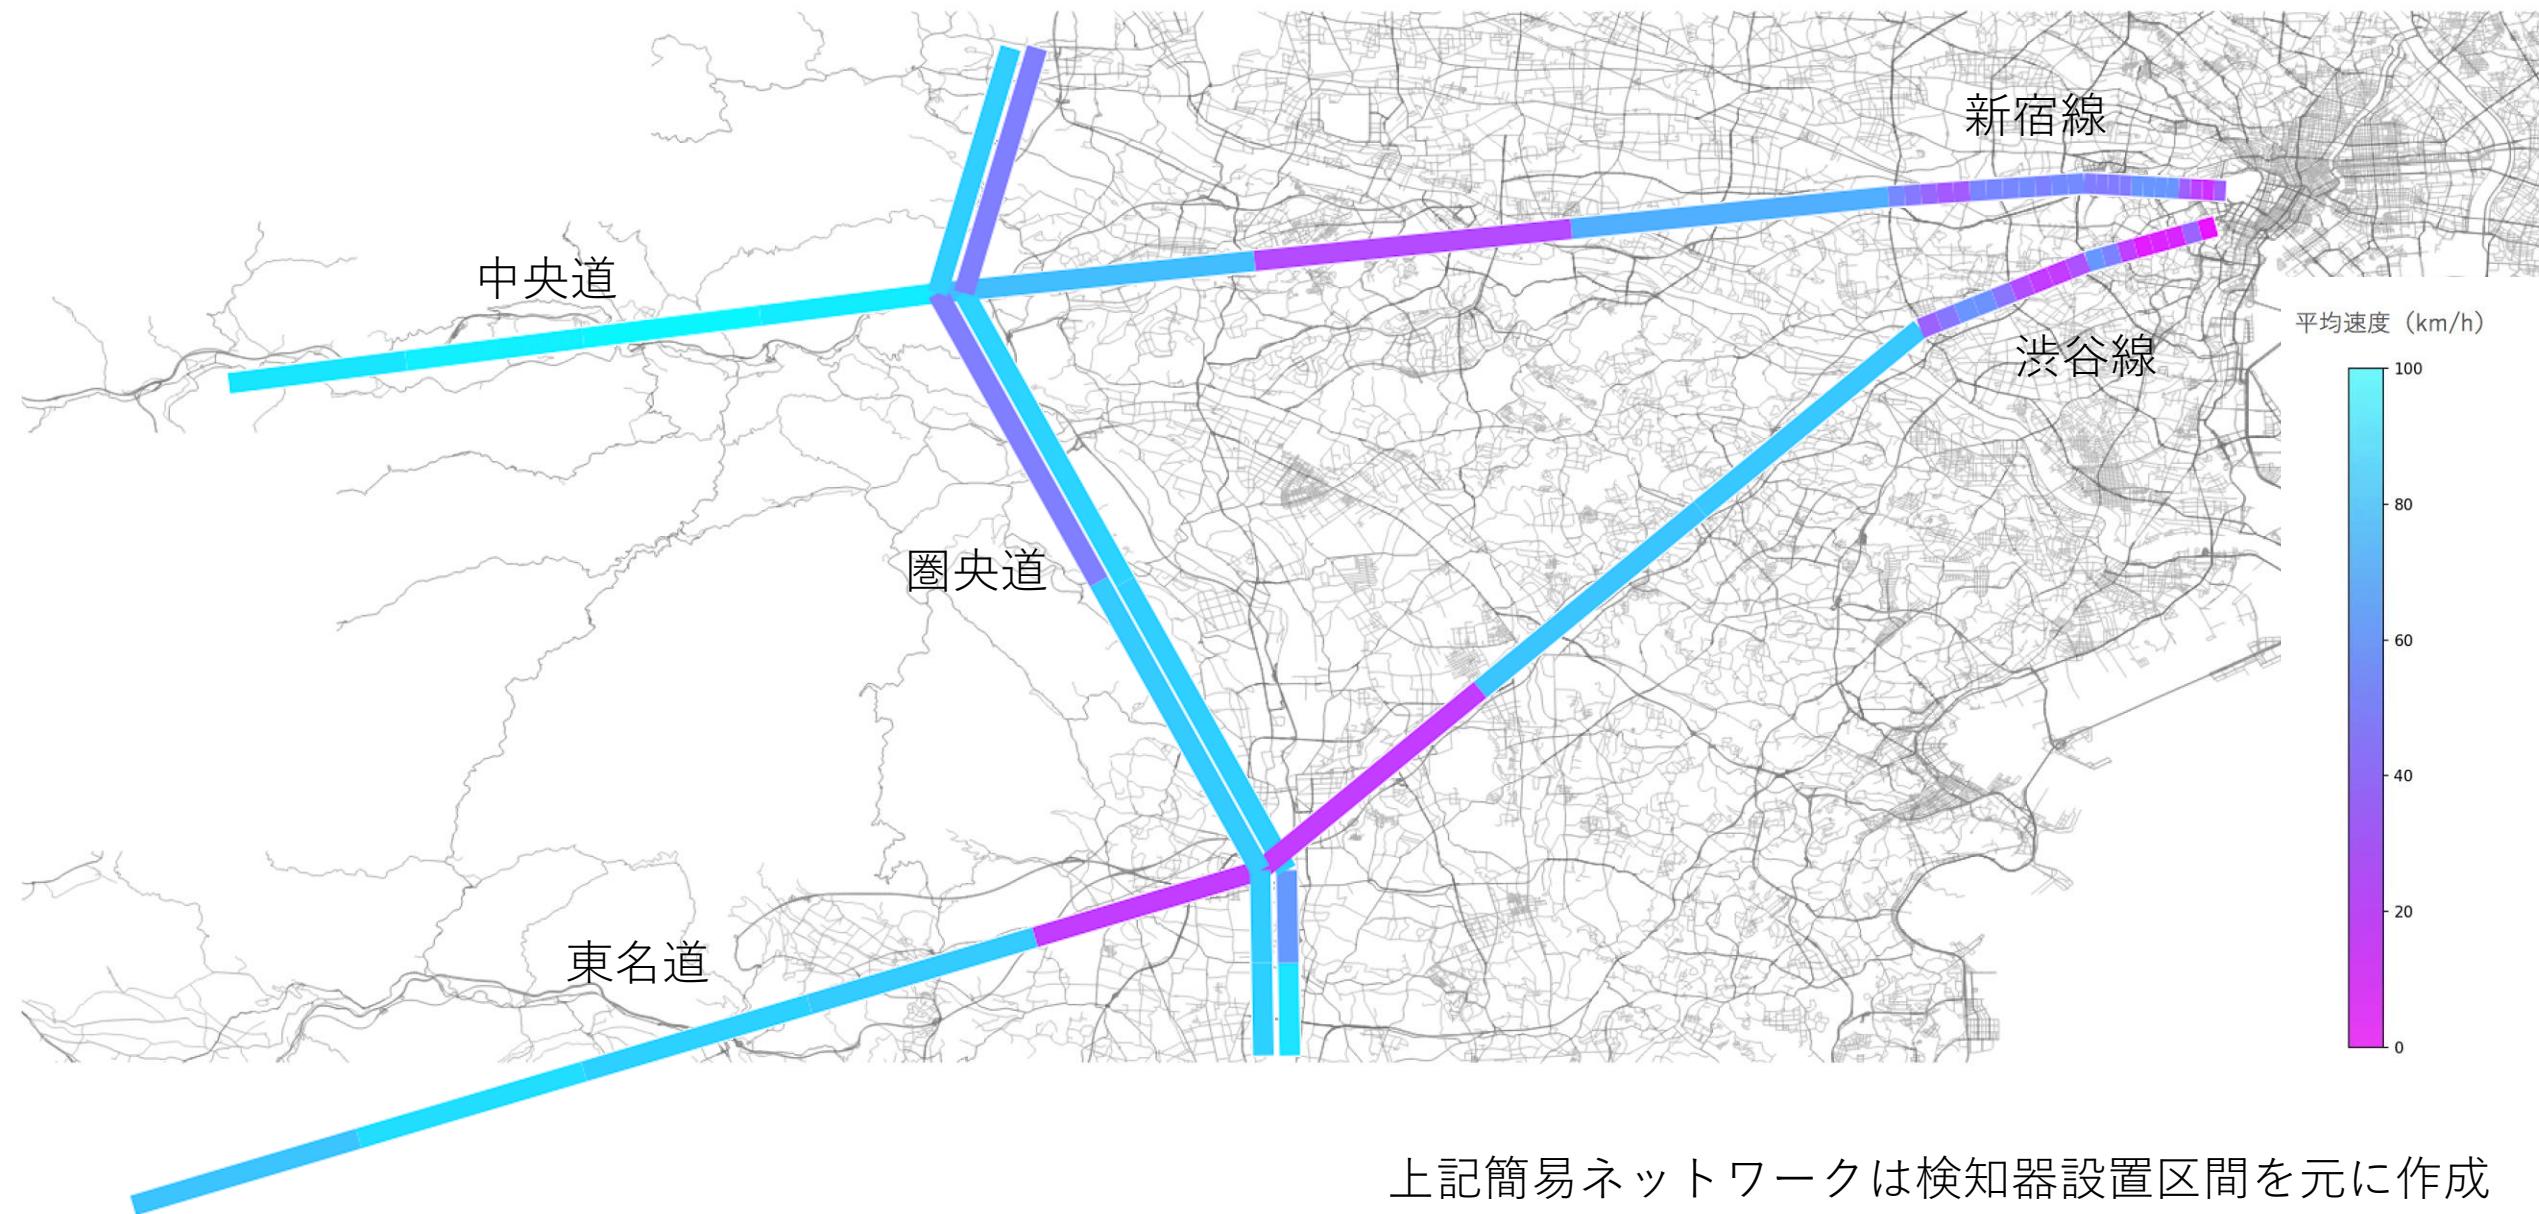
# 首都圏へ流入する主要高速道路



今回は首都圏へ流入する主要高速道路  
**中央自動車道**と**東名高速道路**の交通状態を  
それぞれが接続する首都高速道路の**新宿線**  
および**渋谷線**の交通状態から予測する。



# 首都圏へ流入する主要高速道路（簡易版）



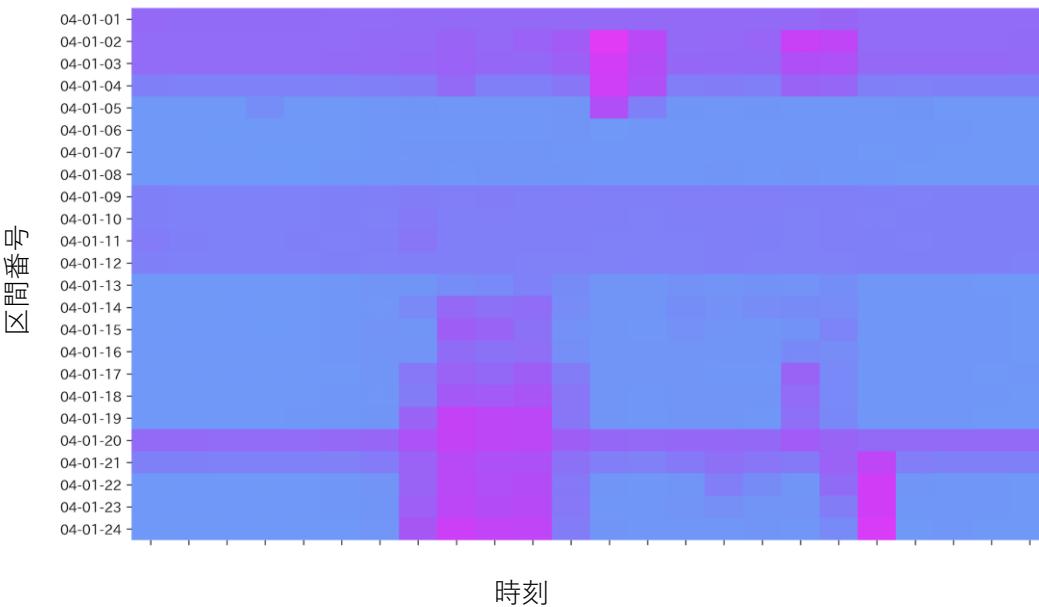
# 対象路線速度変化（アニメーション）



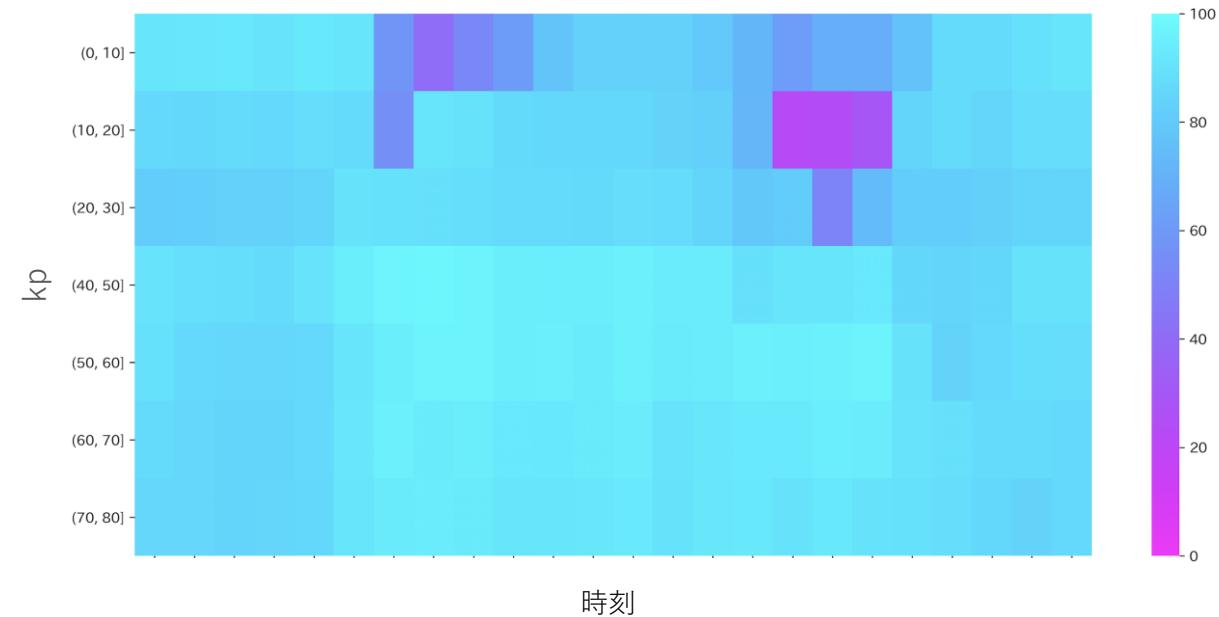
# 時空間図として整理

横軸を時刻、縦軸を位置（キロポスト）として時間的変動を1枚の画像として認識できるよう整理。

以降、**指定された時刻において取得できる範囲の首都高速道路の時空間図**を用いて、**当該時刻以降数時間分の中央道or東名道の時空間図を予測する手法を開発、実装する。**



新宿線の時空間図 (8月1日)

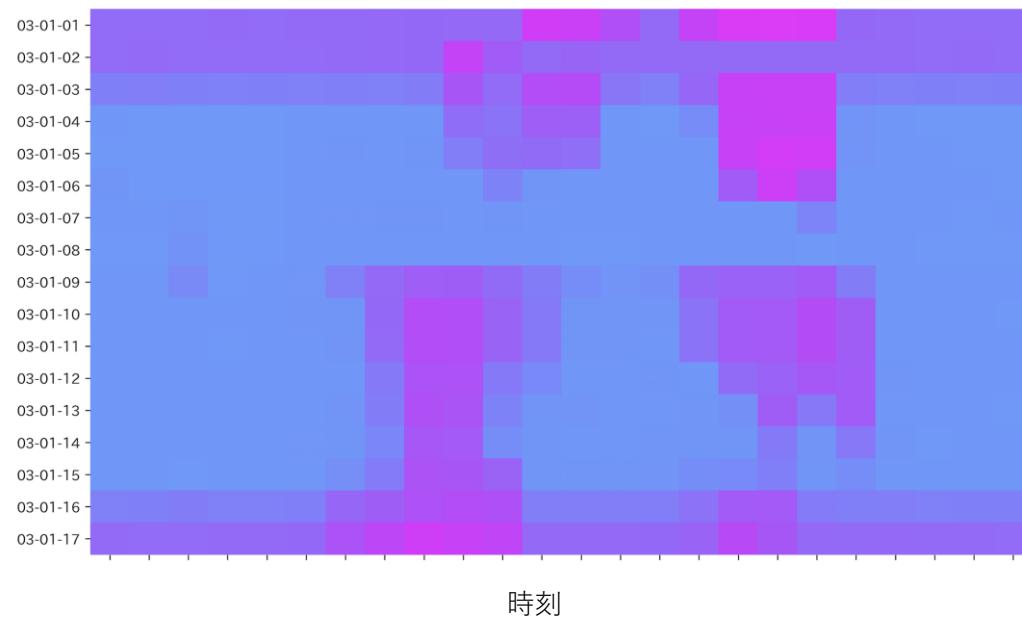


中央道の時空間図 (8月1日)

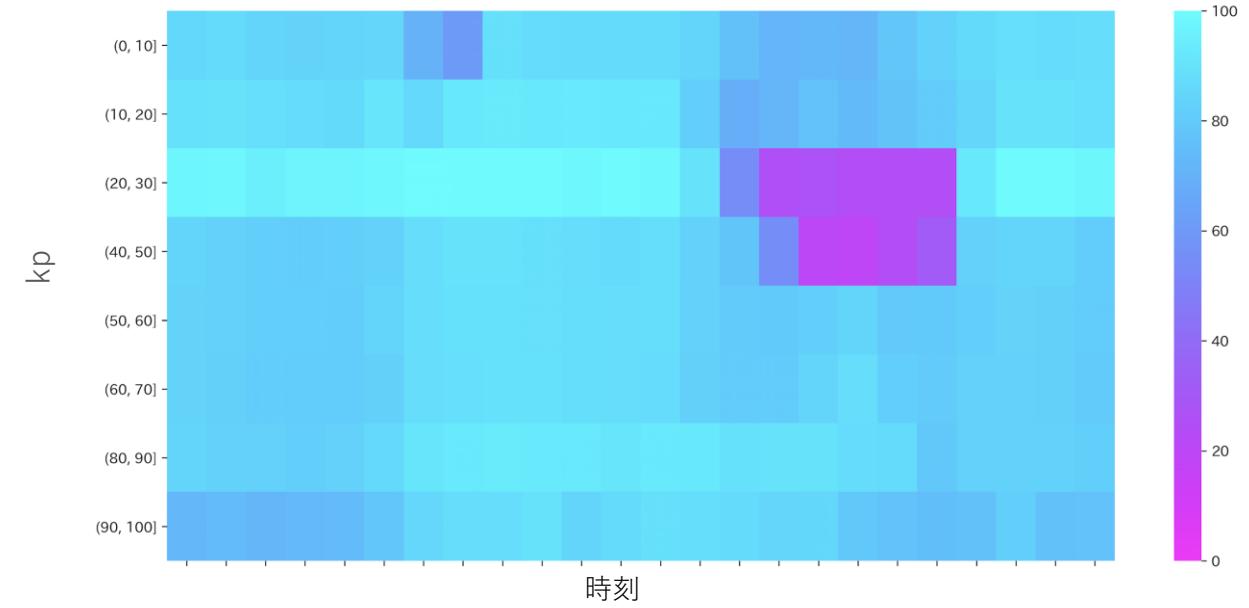
# 時空間図として整理

横軸を時刻、縦軸を位置（キロポスト）として時間的変動を1枚の画像として認識できるよう整理。

以降、**指定された時刻において取得できる範囲の首都高速道路の時空間図**を用いて、**当該時刻以降数時間分の中央道or東名道の時空間図を予測する手法を開発、実装する。**



渋谷線の時空間図 (8月1日)



東名道の時空間図 (8月1日)

# 分析手法・アルゴリズム

# 画像認識のアルゴリズム

## Gray-level Co-occurrence Matrix(GLCM)<sup>①</sup>を用いた類似度の測定

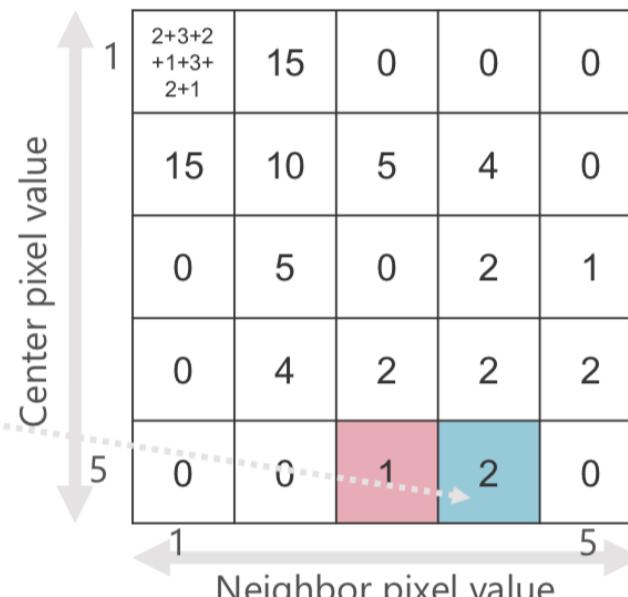
通常画像は各セルの値が個別のデータとなるため、データの次元が膨大になりがちであるが、隣接セルとの値の変動を一つの行列にまとめたGLCMに変換（特徴量の抽出）を行うことにより類似度を簡便に計算。

1	1	1	1
1	2	2	2
1	2	3	4
1	2	4	5

A given image

$$GLCM = \frac{A}{\sum_{i,j} A_{i,j}}$$

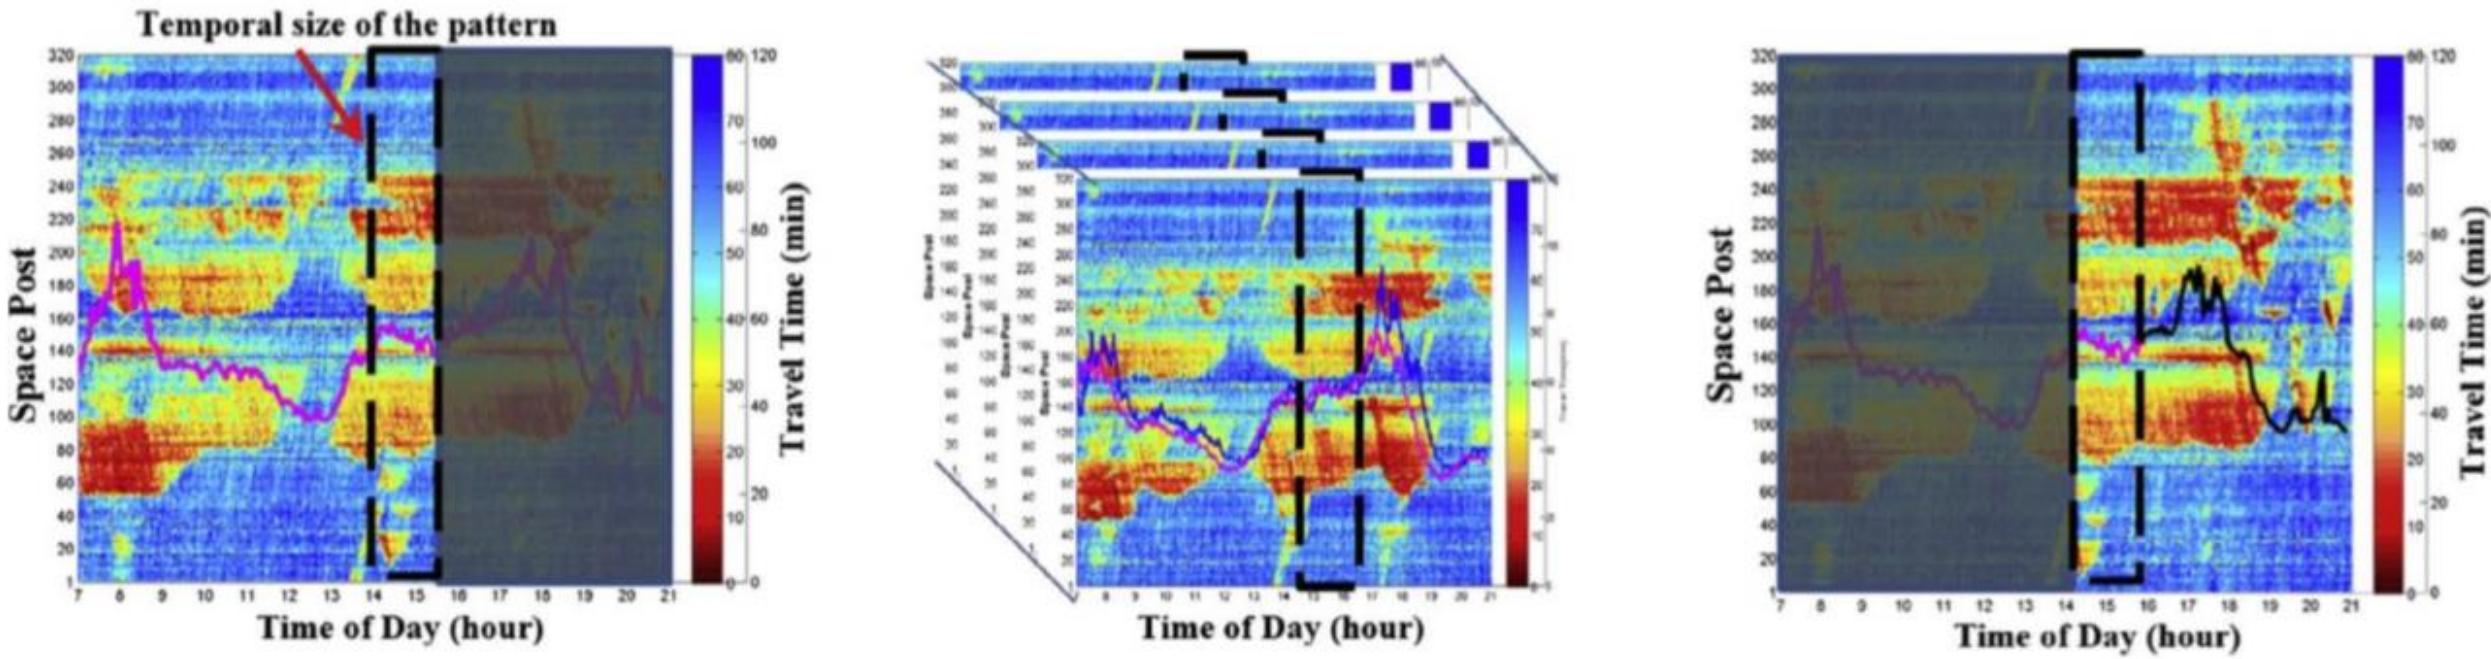
$A_{i,j}$ : Number of neighbors with the center pixel value is  $i$   
and the neighbor pixel value is  $j$



Matrix A

# GLCMを用いた旅行時間予測の既存研究<sup>2)</sup>

Zhang et. al. (2017)は、過去の膨大なtime-space diagramをGLCMに変換し、パターン認識による将来の旅行時間予測を行った。



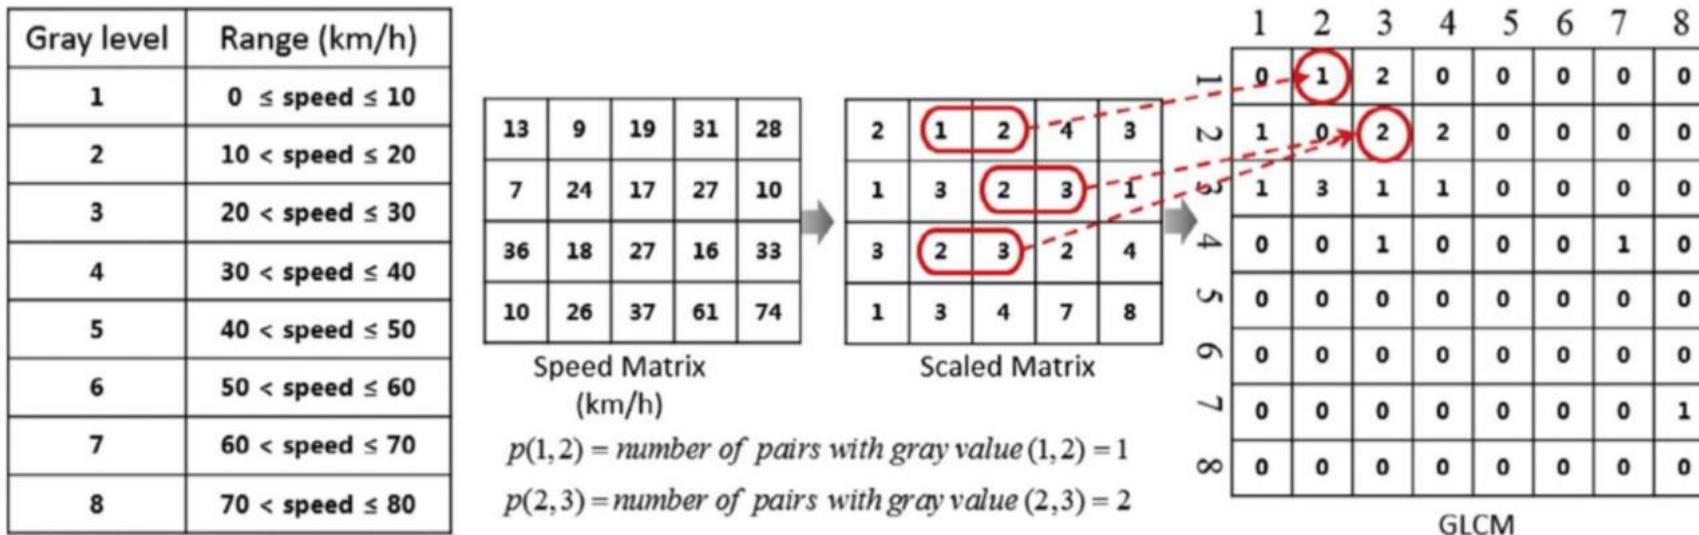
Obtain current traffic states

Extract similar patterns  
from historical database

Predict future travel times

# GLCMを用いた旅行時間予測の既存研究<sup>2)</sup>

Zhang et. al. (2017)は、過去の膨大なtime-space diagramをGLCMに変換し、パターン認識による将来の旅行時間予測を行った。



- Gray levelを設ける。
- 黒枠（時空間図）をSpeed Matrixに変換、Gray levelに基づきScaled Matrixに変換する。
- Scaled Matrixに基づき、GLCMに変換する。

# GLCMを用いた交通状態図の合成

本作品では…

STEP 1 各種時空間図を一定の時間幅ごとに分割

STEP 2 予測対象日・対象時刻以前の首都高速道路の時空間図を用いて、GLCMにより類似するパターンの時空間図を取得

STEP 3 類似すると判定された日時の次の時間幅に対応する中央道or東名道の時空間図を類似度上位から一定数取得し、それぞれGLCMの類似度に応じた重みを付けた上で重ね合わせる。

という手順のプログラムを構築した。

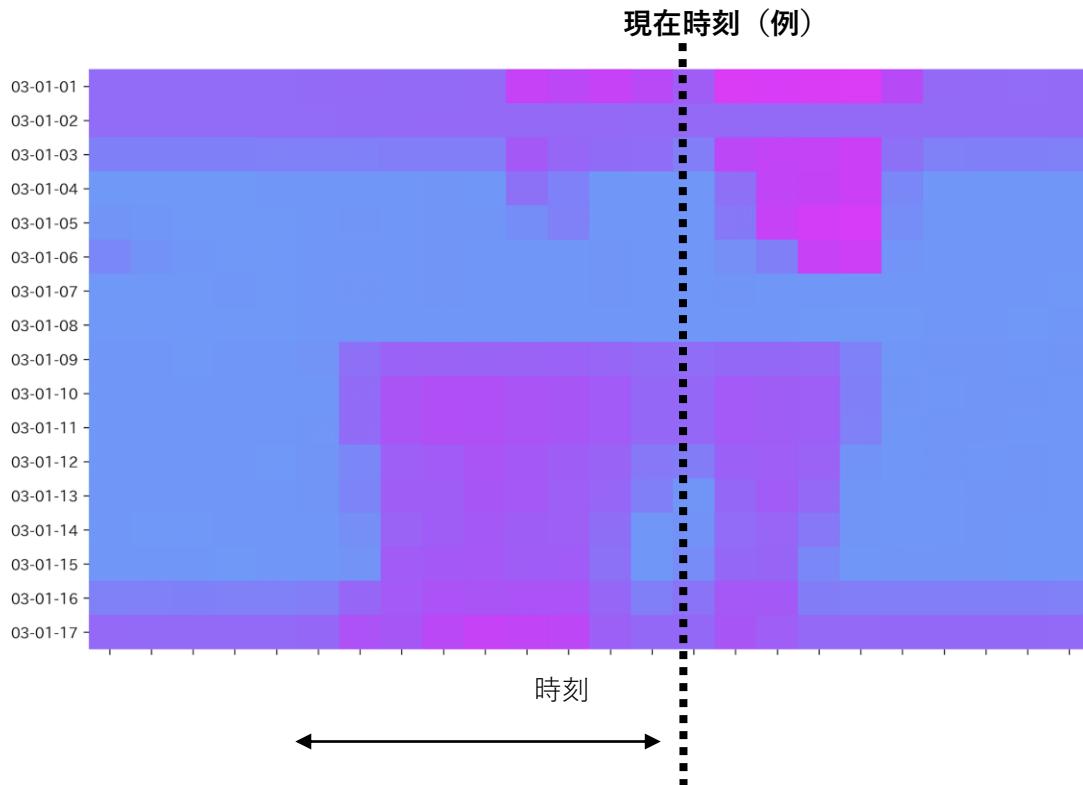
**実際に実装したプログラムは下記URLで公開中**

[https://github.com/sasakiyasushi/data\\_challenge\\_kobe\\_2019](https://github.com/sasakiyasushi/data_challenge_kobe_2019)

# 分析結果

# 類似データの抽出

渋谷線 (2017/8/18)



例えば現在時刻において  
**観測可能な部分**の類似データを抽出

左図と類似していると判定された画像



(2017/8/13)



(2017/8/12)



(2017/8/14)



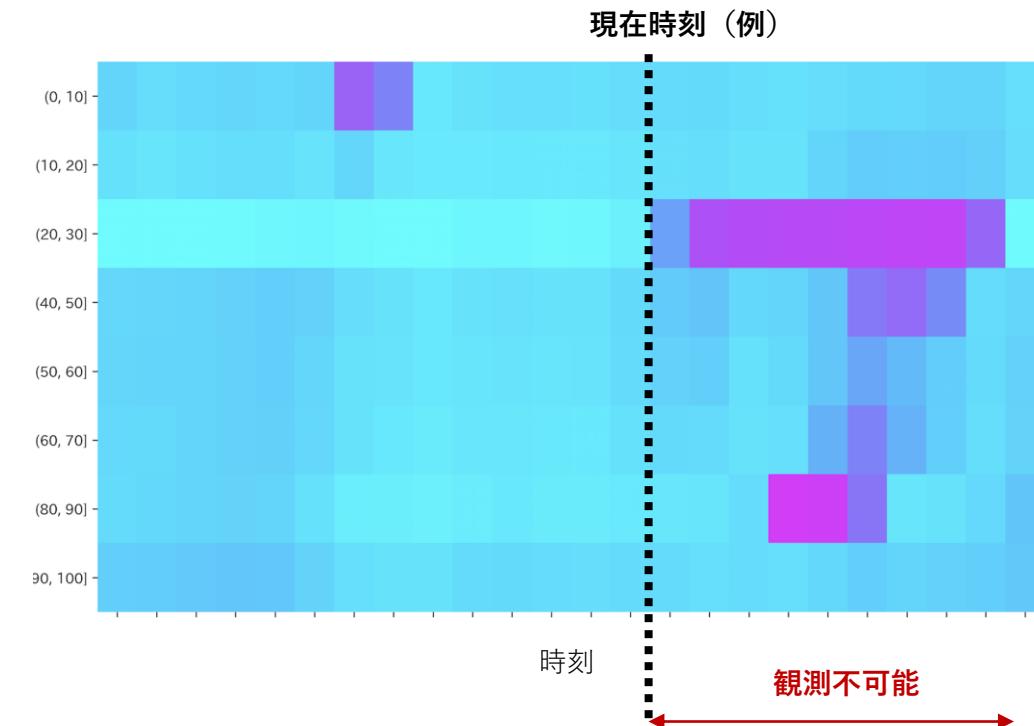
(2017/8/26)



(2017/8/19)

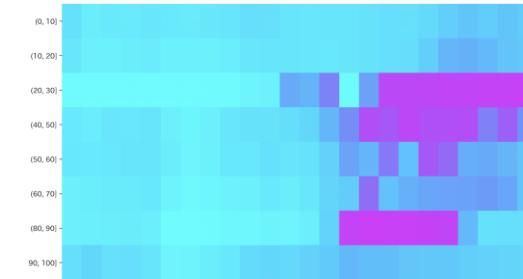
# 対応データ（予測対象）

東名道（2017/8/18）

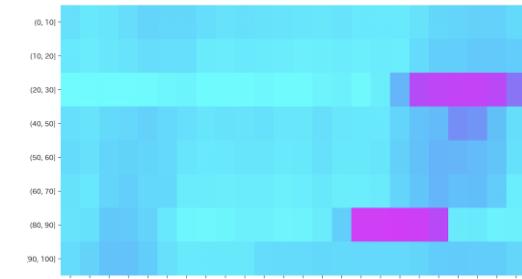


現在時刻以降（**当然観測不可能な部分**）を、前ページで抽出した日時と対応する別日の時空間図から予測

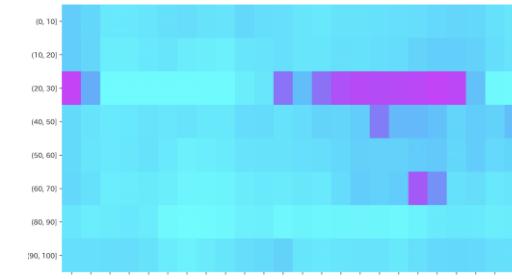
## 対応する別日の時空間図



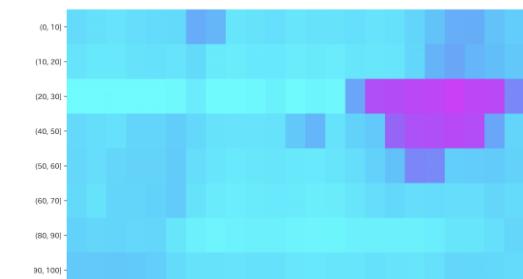
(2017/8/13)



(2017/8/12)



(2017/8/14)

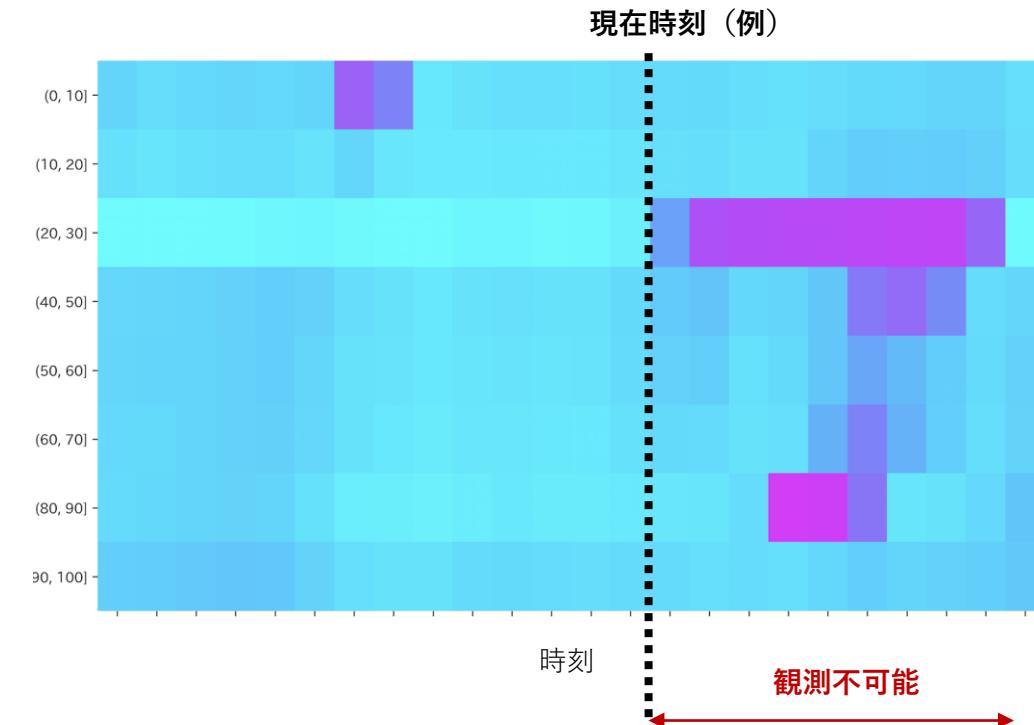


(2017/8/19)

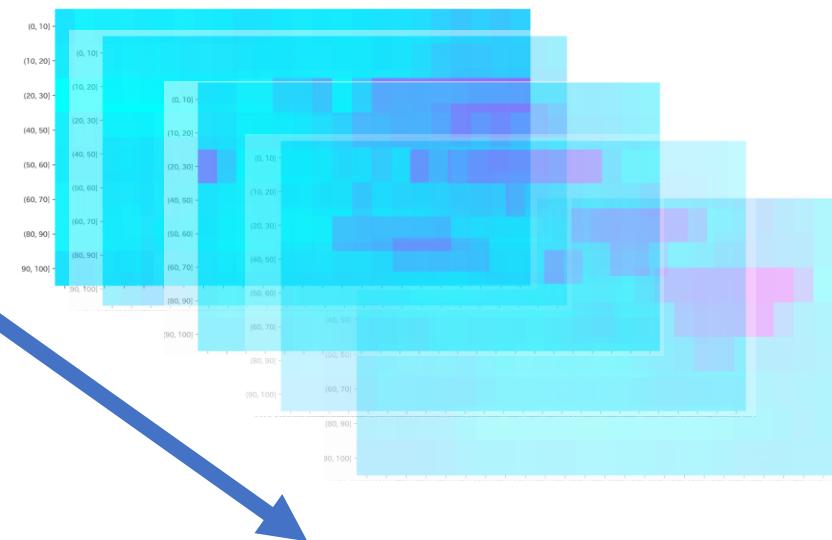
うち判定時刻の次タイムステップのみ抽出

# 対応データ（予測対象）

東名道（2017/8/18）

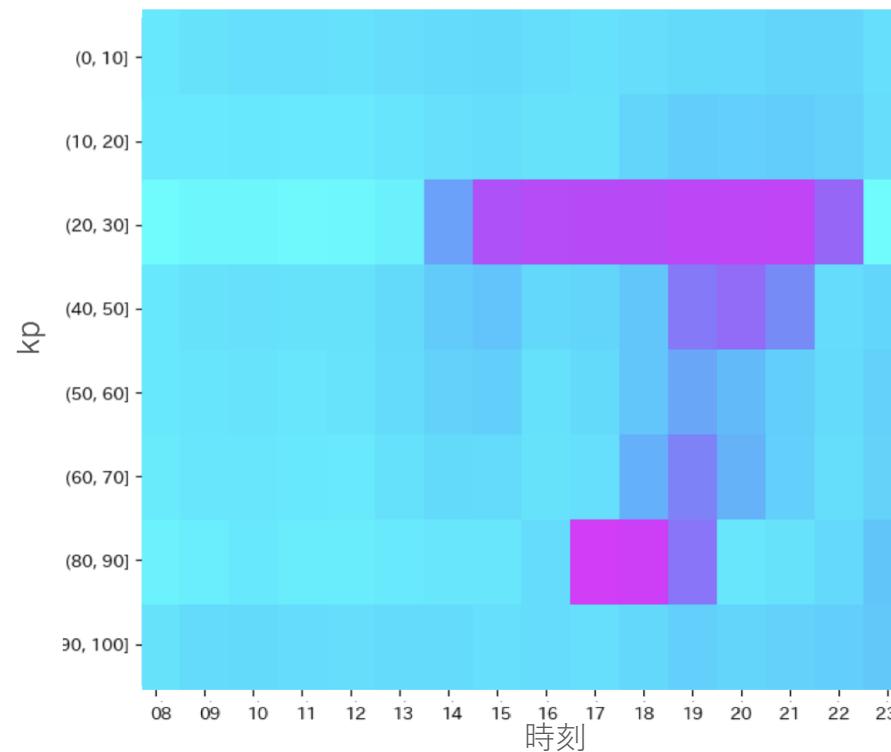


# 対応する過去の時空間図

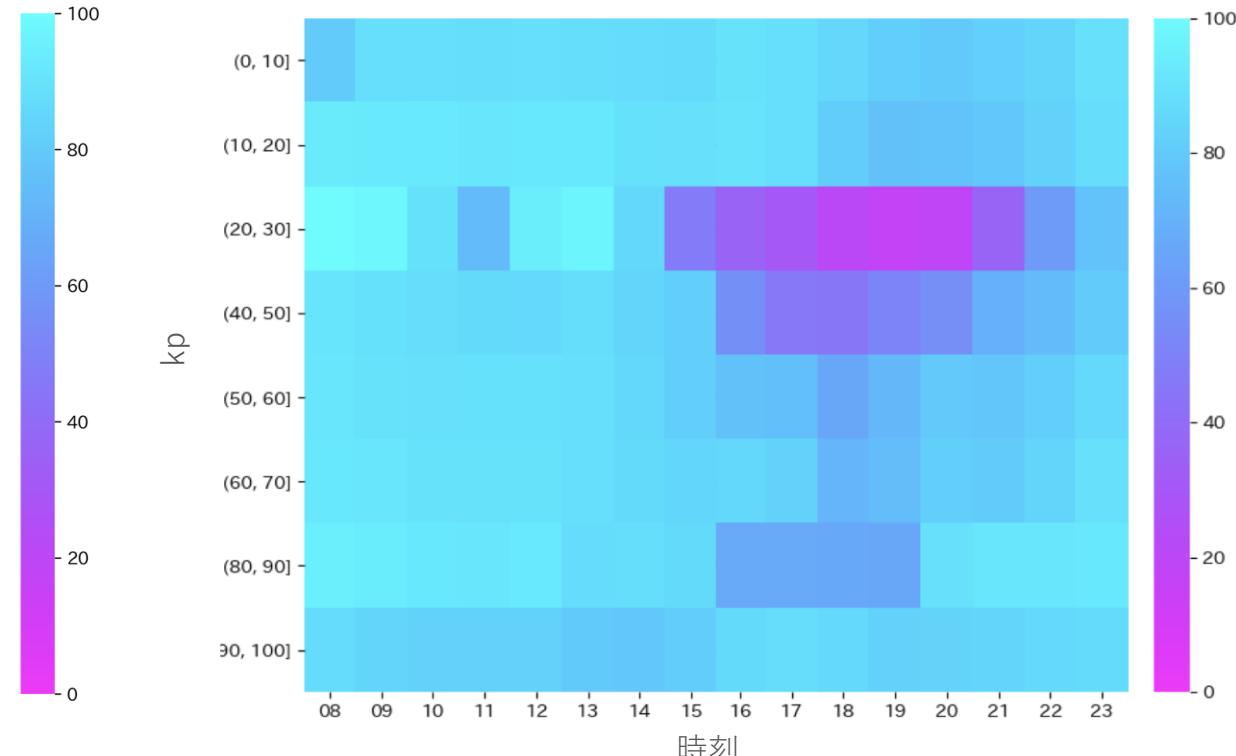


# 予測した時空間図の一例（東名道）

8月18日の東名道の実際の交通状態（左図）と、首都高速道路渋谷線の交通状態画像から、交通状態を予測したもの（右図）  
(設定時刻までの8時間分の首都高速の交通状態をインプットとして東名道の8時間先までの交通状態を予測したケースを例示)



実際に観測された交通状態

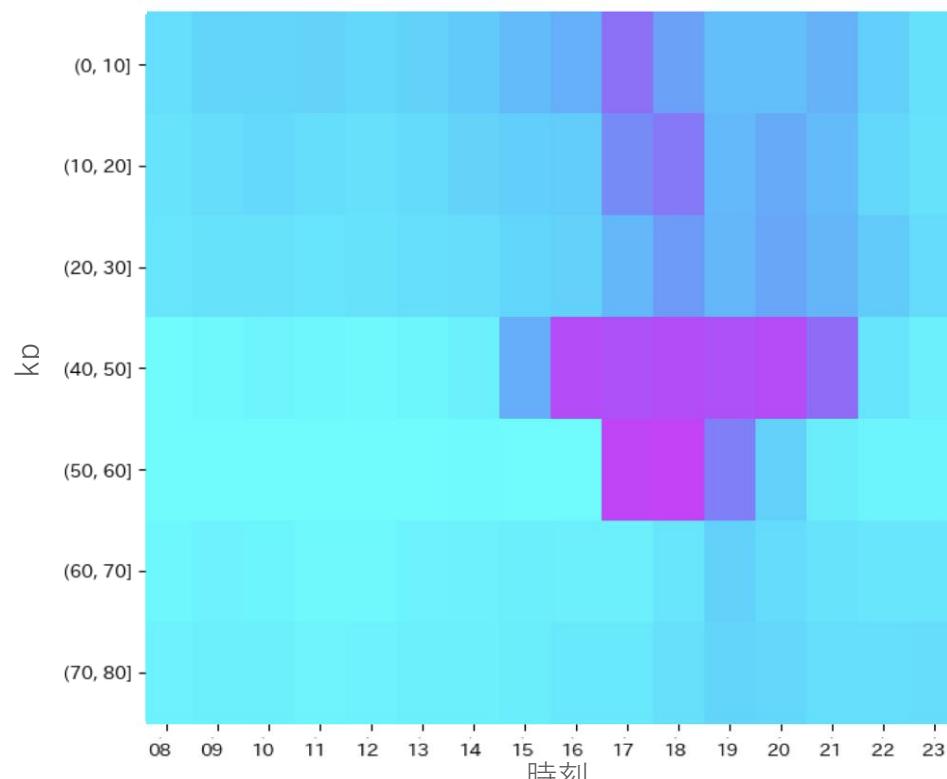


学習・予測した合成画像

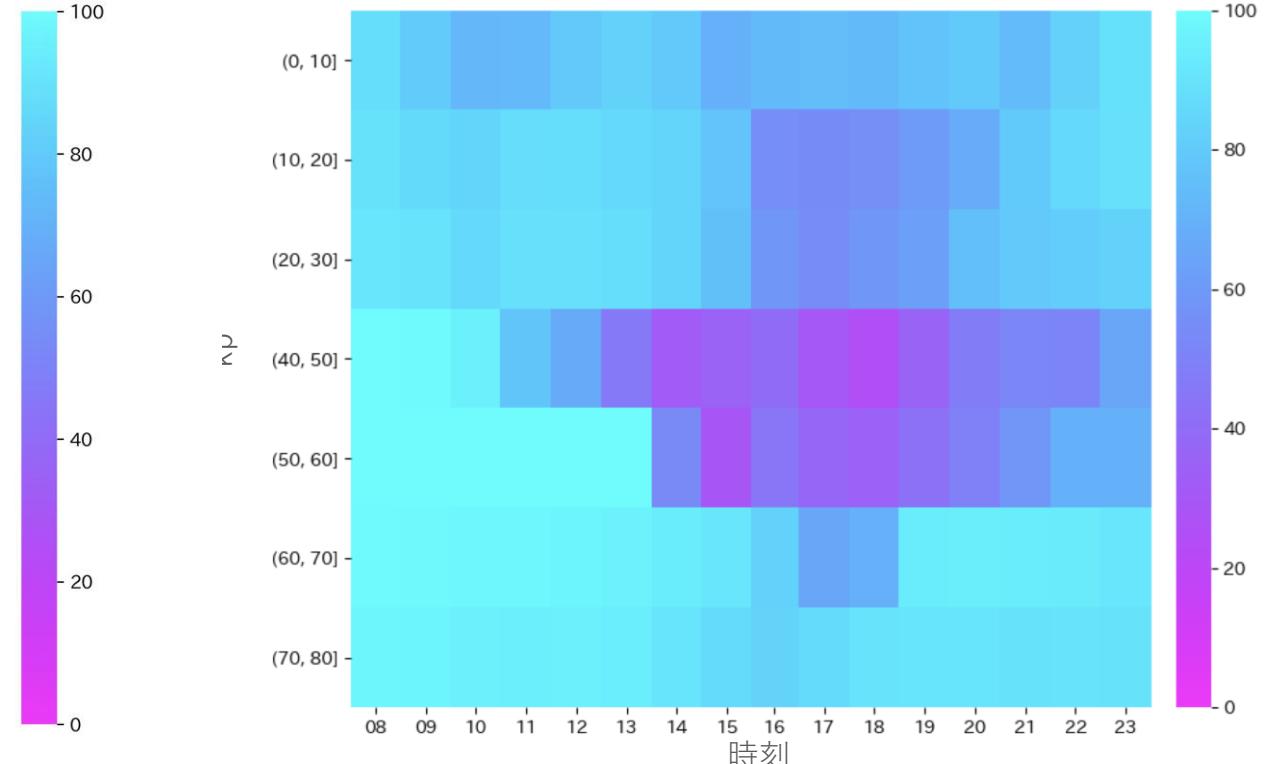
# 予測した時空間図の一例（中央道）

8月18日の中央道の実際の交通状態（左図）と、首都高速道路新宿線の交通状態画像から、交通状態を予測したもの（右図）

（設定時刻までの8時間分の首都高速の交通状態をインプットとして東名道の8時間先までの交通状態を予測したケースを例示）



実際に観測された交通状態



学習・予測した合成画像

おわりに

# おわりに

今回の作品で用いた時空間図は、検知器データの速度情報から作成しているため、観測区間は検知器設置区間に依存する。

本資料の基礎分析（可視化）で用いたプローブデータが今回対象とした区間でも入手できるようになれば、**時間的にも空間的にも、より高解像度な速度情報を取得可能なため、より柔軟な学習・予測データセット作成が可能となる。**

今後、日々蓄積されていく膨大な各種交通データについて、**時空間図およびGLCMという特徴行列への変換**を行うことにより、現実的な学習速度でパターン認識・予測への活用が行えるという可能性を示した。

# 参考文献

- 1) Hall-Bayer, M., GLCM Texture. A Tutorial, Version 2.3., Department of Geography, University of Calgary, Calgary, Alberta, Canada, 2000.
- 2) Zhang, Z., Wang, Y., Chen, P., He, Z., Yu, G., Probe data-driven travel time forecasting for urban expressways by matching similar spatiotemporal traffic patterns. Transport. Res. Part C Emerging Technol. 85, pp. 476-493, 2017.